PEC MOTORES DE COMPUTACIÓN PARALELOS MIGUEL PÉREZ CARO

En el presente documento se tratará de resolver las cuestiones presentadas en el ejercicio de la prueba de evaluación continua de la asignatura Motores de Computación Paralelos.

1. Razonar y justificar qué herramienta se utilizará en cada paso.

Para la realización de la pec se va a hacer uso únicamente de la herramienta SparkSQL, que es un módulo de Spark orientado al preprocesamiento de datos estructurados. Hay diferentes formas de interactuar con SparkSQL, incluyendo SQL, Dataframes API o Datasets API. Para resolver los ejercicios se va a utilizar el api de Python para Spark denominado pyspark. El motivo por el que se va a usar solo esta herramienta es por mi experiencia con Python y porque es la herramienta de todas las vistas que más uso en el trabajo, por lo que en un sentido profesional también me beneficia.

2. Cargar los diferentes ficheros en las herramientas seleccionadas y sacar un listado de sus contenidos por pantalla o a fichero de hdfs.

Como se ha comentado en el ejercicio anterior, se va a hacer uso de SparkSQL, y en este ejercicio se han cargado ambos archivos de su ubicación en el local de la máquina virtual, que en este caso es /home/bigdata/Escritorio/pec/, estableciendo como encoding el ISO-8859-1 para poder visualizar caracteres como los acentos. Para el caso del archivo PECMunicipios.csv, se ha generado un schema que se pasa como argumento a la hora de cargar el archivo, y se han eliminado los espacios, y en el caso del archivo PECElecciones.csv, una vez cargado, se ha modificado el tipo de todas las columnas a integer. A continuación, se muestran dos capturas de pantalla de los resultados de ambos archivos al imprimirlos por pantalla:

ē ±											
								OMPROMÍS-EUPV ERC-CA			
	4001										
						8641					
		141380									
	4014										
							254				
	4017										
	4018					112					
	4819		1961		611	103					

3. Generar un fichero con el top 10 de población de municipios de España y otro con el bottom 10 de población. Necesitamos el nombre de los municipios y su población sólo.

Para la realización de este ejercicio se trabaja solo con el dataframe obtenido del archivo PECMunicipios.csv. A partir de dicho dataframe, se ordena con los valores de la población de forma ascendente y descendente, y, en segundo lugar, es decir, en caso de que dos municipios tengan la misma población, se ordena alfabéticamente según el nombre del municipio.

Una vez ordenados, para cada archivo se seleccionan únicamente las columnas correspondientes al municipio y a la población, y se guarda dicho dataframe en formato csv con los encabezados en el path especificado. Se adjuntan los ficheros generados en el zip de la pec, que son:

- ej3-municipios-mayor-pob: contiene el fichero generado con los 10 municipios de mayor población incluyendo el municipio y su población.
- ej3-municipios-menor-pob: contiene el fichero generado con los 10 municipios de menor población incluyendo el municipio y su población.

Finalmente se muestra a continuación una captura de pantalla del código generado para la realización del ejercicio:

```
# EJERCICIO 3

A 10 A 37 # 224 ^ v

## Brdenar el dataframe de municipios de forma ascendente y descendente

df3_asc = df_mun.sort(df_mun.Poblacion.asc(), df_mun.Hunicipio.asc())

df3_desc = df_mun.sort(df_mun.Poblacion.desc(), df_mun.Hunicipio.asc())

## Seleccionar los 10 primeros municipios y quardar el archivo en el path seleccionado con el encabezado

df3_asc_10=sfs_asc_select("Municipio", "Foblacion").limit(10)

df3_asc_10=sfs_asc_format('csv').option('neader', True).mode('overmrite').option('sep'_z',')\

.save('/home/bigdata/Escritorio/pec/ej3-municipios - guardar el archivo en el path seleccionado con el encabezado

df3_desc_10= df3_desc_select("Municipio", "Foblacion").limit(10)

df3_desc_10=sff_desc_select("Municipio", "Foblacion").limit(10)

df3_desc_los_select("format('csv').option('header', True).mode('overmrite').option('sep'_z',')\

.save('/home/bigdata/Escritorio/pec/ej3-municipios-mayor-pob')

## Apartado a: Mostrar lo mismo incluyendo la Comunidad Autónoma y la Provincia

df3_asc_total_10= df3_asc.select("Semunidad", "Provincia", "Hunicipio", "Foblacion").limit(10)

df3_desc_total_10=mf3_desc_select("Gemunidad", True).mode('overmrite').option('sep'_z',')\

.save('/home/bigdata/Escritorio/pec/ej3-com-prov-mun-mayor-pob')

df3_desc_total_10=df3_desc_select("Gemunidad", "Provincia", "Hunicipio", "Poblacion").limit(10)

df3_desc_total_10=mf3_desc_select("Gemunidad", "Provincia", "Hunicipio", "Poblacion").limit(10)
```

a) Sacar además del nombre la autonomía y la provincia.

Entendiendo que en este apartado se pide el mismo archivo que en el anterior, pero incluyendo los valores de la comunidad y de la provincia, simplemente se seleccionan también dichas columnas, y se adjuntan los ficheros generados al zip de la pec:

- ej3a-com-prov-mun-mayor-pob: contiene el fichero generado con los 10 municipios de mayor población incluyendo la comunidad, la provincia, el municipio y su población.
- ej3a-com-prov-mun-menor-pob: contiene el fichero generado con los 10 municipios de menor población incluyendo la comunidad, la provincia, el municipio y su población.
- 4. Queremos saber los 10 municipios donde ha habido más participación (el porcentaje de votos respecto el censo es más alto) y donde ha habido más abstención. Generaremos un fichero del top y uno del bottom con los datos del municipio y el % de participación.

En primer lugar, se unen ambas tablas por el campo código, ya que se necesitan tanto los datos del municipio como los resultados de las elecciones. Para generar la participación, se entiende que los votos son la suma de Votantes (Válidos + Nulos) y Blancos, ya que se entiende que son aquellas personas que han ido a votar, y se genera el campo participación resultante de la división (Votantes + Blancos) / Censo.

A continuación, se ordena el dataframe de forma ascendente y descendente por la participación, y en segundo lugar alfabéticamente por el nombre del municipio, y se generan los archivos, entendiendo como datos del municipio la comunidad y provincia a la que pertenece, el nombre del municipio, la población y el censo. Nuevamente, se adjuntan los ficheros generados al zip de la pec:

- ej4-municipios-mayor-participacion: contiene el fichero generado con los 10 municipios en los que hubo una mayor participación, incluyendo la comunidad, la provincia, el municipio, la población, el censo y la participación.
- ej4-municipios-menor-participacion: contiene el fichero generado con los 10 municipios en los que hubo una mayor participación, incluyendo la comunidad, la provincia, el municipio, la población, el censo y la participación.

Finalmente se muestra una captura de pantalla del código utilizado:

En los municipios con mayor participación, se observa que todos ellos superan el 100% de participación, y se debe a que la suma de votantes es igual al censo, de forma que hay una serie de votos blancos que hacen que la participación sea superior al censo, mostrando algún tipo de irregularidad en dichos votos blancos.

5. ¿Existe algún municipio que haya votado al 100% a un partido? Si es así, ¿cuál es y a qué partido? Si no es así, sacar una lista de los 10 municipios donde su concentración de voto porcentual haya sido mayor y a qué partido.

En primer lugar, hay que verificar si existe algún municipio que haya votado al 100% a un partido. Como se ha comprobado, en una prueba que se realizó durante la realización del ejercicio que 4 y que después fue descartada, que la suma de votantes, es decir, válidos más nulos, nunca supera el censo de la población, se entiende que un municipio ha votado al 100% a un partido cuando el número del campo Votantes, sea igual al número de votos que ha recibido un partido, por lo tanto se entiende que si hay un voto nulo nunca se podrá dar tal circunstancia, a pesar de que se desconozca la intención de voto de dicho voto nulo, y que es independiente de la participación, de forma que nos concentramos únicamente en la población que ha ido a votar.

Para cada municipio se comprueba si el número del campo votantes es igual al número de votos de cualquiera de los partidos políticos, obteniendo los siguientes municipios:

									-COMPROMÍS-EUPV	
		Congostrina								
	Burgos									

Se puede comprobar en la imagen que se han obtenido 5 municipios, de forma que en ninguno de ellos la participación fue del 100%, pero todos los que fueron a votar, lo hicieron al Partido Popular. De esta forma se resuelve la primera pregunta del ejercicio y no es necesario adentrarse en la lista de los 10 municipios donde la concentración de voto porcentual haya sido mayor.

6. Necesitamos comparar los datos de participación de la "España vacía" con los de la "España llena". Saquemos el índice de participación (votos/censo) por provincia, ordenado de mayor a menor.

Para obtener el resultado deseado, se parte del dataframe resultante de unir los dos iniciales, se agrupa por provincia y se suman los valores de los campos necesarios para calcular la participación, que son los mismos que en el ejercicio 4, es decir, Votantes, Blanco y Censo, calculando dicho valor tal que (Votantes + Blanco) / Censo. Finalmente se ordena por la participación, y se muestra por pantalla la provincia y su participación correspondiente:

```
Participacion|
               Segovia 76.35599694423225
                 Ávila| 76.1333869877835|
           Valladolid | 76.09396218966054 |
               Cuenca | 75.95034710573177 |
 Valencia / València | 75.88221081276274 |
             La Rioja | 75.23293058883137 |
             Palencia | 74.72074390315223 |
               Madrid 74.6487720505999
          Guadalajara | 74.59353574926543 |
|Castellón / Castelló|74.30647033186588|
               Burgos | 73.92353600191653 |
            Cantabria | 73.89674019930969 |
                Toledo | 73.36091454741825 |
             Albacete | 73.35217007134662 |
            Salamanca | 73.08942304598256 |
                Teruel | 72.80854921043843 |
             Zaragoza 72.77624553537609
  Alicante / Alacant | 72.50870823122504 |
                  Jaén 72.39360352951122
               Cáceres | 71.9838410961203 |
```

7. Queremos saber si los municipios grandes son representativos en los resultados de las comunidades. Debemos sacar para cada comunidad el municipio que tiene más población y comparar el partido con más participación del municipio con la comunidad. ¿Coinciden? ¿No coinciden? ¿Tiene que ver con que represente más de un determinado porcentaje de población de la comunidad?

En primer lugar, se crea una función para convertir el dataframe de ancho a largo, es decir, todas las columnas de los partidos pasarán a ser una fila para municipio, creándose una columna Partido para recoger todos los partidos para cada municipio, y una columna Votos, que contendrá el número de votos por partido en cada municipio, de forma que, en vez de tener una fila por municipio, se tendrá tantas filas por municipio como partidos haya.

Se entiende que el enunciado pide obtener el partido con más participación, que obviamente es el más votado, para el municipio más poblado de cada comunidad, y compararlo con el partido más votado en dicha comunidad.

Se comienza calculando el partido más votado para cada comunidad, de forma que obtenemos el dataframe resultante de modificarlo de ancho a largo, se agrupan por comunidad y partido, sumando el número de votos, de forma que se obtiene la cantidad de votos por partido en cada comunidad, y simplemente hay que agrupar por comunidad y seleccionar el máximo de votos.

Para el cálculo del partido más votado en el municipio más poblado de cada comunidad hay que, primero, calcular el municipio más poblado, para lo cual, se agrupa por comunidad, seleccionando el máximo de población. Una vez lo tenemos, con un proceso idéntico al anterior, se consigue el partido más votado en cada municipio, y se puede obtener el siguiente dataframe:

		Municipio Partio			
		Pamplona / Iruña		PP	
121660	PPI	Zaragozal	251595	PPI	Aragón
159079	PPI	Valencia	917405	PP I	Comunitat Valenciana
196341	ECPI	Barcelonal	848752	ECP	Catalunya
43755	PPI	Santander	139618	PPI	Cantabria
35531	PPI	Badajoz	244534	PP	Extremadura
52297	PPI	Vigol	643849	PP	Galicia
58394	PP	Palma de Mallorca	162861	PP	Illes Balears
51127	PPI	Gijón	207885	PP	Principado de Ast
15956	PP	Ceuta	15956	PP	Ciudad de Ceuta
64080	PP	s Palmas de Gra	332795 La	PP	Canarias
129961	PP	Sevilla	1422542	PPI	Andalucía
109773	PPI	Murcial	332437	PPI	Región de Murcia
38470	PPI	Albacete	475191	PPI	Castilla – La Mancha
13478	PPI	Melilla	13478	PPI	Ciudad de Melilla
75414	PP	Valladolid	639851	PPI	Castilla y León
33023	PPI	Logroño	73371	PPI	La Rioja
50722	EAJ-PNV	Bilbao	333716	MOS-IU-EQUO	País Vasco PO
696804	PP	Madrid	1316804	PP	Comunidad de Madrid

Se puede comprobar como en todos los casos, menos en el País Vasco, el partido más votado en el municipio más poblado de la comunidad es el mismo que el partido más votado en la comunidad, lo cuál tiene bastante sentido ya que generalmente dichos municipios representan un porcentaje muy alto de la población de dicha región, por lo que ser el partido más votado en esos municipios es una ayuda considerable para serlo en la comunidad. Además, como se podrá comprobar en el siguiente ejercicio, a pesar de que el partido más votado en la comunidad del País Vasco no sea el mismo que en Bilbao, dicho partido, Podemos-IU-Equo es el segundo partido más votado en el municipio a menos de 700 votos del primero, por lo que también nos reafirma en la conclusión de que los resultados en los municipios más poblados son representativos de los de la comunidad.

8. Vamos a analizar los datos de los municipios grandes y de los municipios pequeños.

1) Sacaremos la participación y el top 5 de partidos votados en los 20 municipios con más población.

El primer paso es ordenar por población de forma descendente y obtener los 20 primeros municipios, para después hacer uso de la función del ejercicio anterior transformando el dataframe de ancho a largo. Se crea una ventana por cada municipio, ordenados los partidos por el número de votos, y se crea un campo nuevo que hace un ranking de los partidos según los votos obtenidos por cada municipio, para después hacer un filtro a ese campo de forma que nos quedamos con los que tengan un ranking menor a 6, que da como resultado los 5 partidos más votados por cada municipio, y por último se genera la participación en estos municipios de igual forma que en ejercicios anteriores. Para una mejor comprensión de los resultados, se adjunta un archivo con los datos en formato largo, es decir, 5 filas por cada municipio con los partidos más votados, y en formato ancho tras aplicar la función pivot a la tabla, obteniendo una columna por cada partido que se encuentra en uno de los 5 más votados de cada municipio, que da como resultado una fila por municipio. Se adjuntan ambos archivos al zip de la pec:

- ej81-partidos-mas-votados-largo: contiene los resultados generados para el formato largo en un fichero csv
- ej81-partidos-mas-votados-ancho: contiene los resultados generados para el formato ancho en un fichero csy

También se adjunta una captura de pantalla de los resultados en formato ancho:

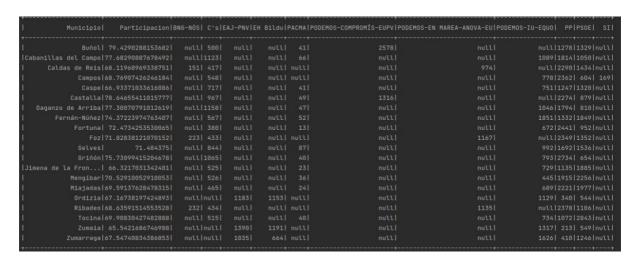


2) Sacaremos la participación y el top 5 de partidos votados en los 20 municipios con menos de 10000 habitantes de España.

El procedimiento para obtener los 5 partidos más votas es idéntico, con la excepción de que, a la hora de ordenar por población, se ha de especificar un filtro de menor de 10000 habitantes para después obtener los 20 primeros municipios. De nuevo, se adjuntan ambos archivos al zip de la pec:

- ej82-partidos-mas-votados-largo: contiene los resultados generados para el formato largo en un fichero csv
- ej82-partidos-mas-votados-ancho: contiene los resultados generados para el formato ancho en un fichero csv

También se adjunta una captura de pantalla de los resultados en formato ancho:



3) Comparemos resultados. ¿Cómo de comportan los diferentes municipios y partidos? ¿Tiene que ver la participación con que gane un partido u otro? ¿Y la provincia o autonomía?

En los municipios más poblados se puede comprobar el bipartidismo que aún se podría decir existe en este país, ya que son dos de los partidos que aparecen en todos los municipios, a los que se suma un tercero que emergió con fuerza a principios de la década pasada que es Podemos, el cuál, en todas las variantes en las que se presentó según la región, también aparece representado en todos los municipios. El cuarto partido político que también aparece ampliamente representado es Ciudadanos, que está presente en todos los municipios excepto Barcelona, ya que los 5 primeros puestos son ocupados por PP, PSOE y 3 partidos de tendencia nacionalista, y en Bilbao y Vitoria. Por lo tanto, se puede observar en una mayoría que estos 4 partidos son los más votados, a excepción de los territorios con tendencia nacionalista, donde aparecen partidos políticos propios de esa región con la misma tendencia excluyendo a Ciudadanos. El que parece el quinto partido en la mayoría de los municipios es Pacma, aunque la cantidad de votos es muy baja y no se puede ni comparar con el resto de los partidos. También se puede aprecia como la fuerza nacionalista es mayor en el País Vasco y en Cataluña ya que los partidos de dicha tendencia están más representados que por ejemplo en Galicia, donde a pesar

de que el Bloque Nacionalista Galego es la quinta fuerza en los municipios gallegos, está lejos de los otros 4 partidos políticos.

En los municipios más poblados a partir de 10.000 habitantes pasa algo similar, que se puede considerar razonable ya que es una cantidad de habitantes suficiente para esperar un comportamiento similar que en los grandes municipios. Nuevamente PP, PSOE y Podemos se encuentran representados en todos los municipios, y Ciudadanos únicamente no aparece en los municipios vascos, por lo que se puede considerar el mismo comportamiento que en el caso. También aparece como quinto partido más representado Pacma, y los partidos con tendencia nacionalista en sus respectivas regiones.

Observando los resultados, la participación no parece significativa con el resultado final, por lo que no considero que influya en que gane un partido u otro, pero la región si que es determinante, ya que, en los municipios grandes, en todos ellos el partido más votado es el PP, excepto en los municipios catalanes y vascos, donde son partidos de una tendencia más nacionalista, como las variantes de Podemos en dichas regiones o el Partido Nacional Vasco. En cambio, en los municipios de menor número de habitantes, aunque se sigue apreciando que la región es importante porque de nuevo en los municipios vascos el partido más votado fue de tendencia nacionalista vasca, en el resto de municipios está más repartido, aunque sigue habiendo una mayor cantidad de municipios donde el partido más votado fue el Partido Popular.