## PEC – BASES DE DATOS ANALÍTICAS Y DATA WAREHOUSE

Esta prueba de evaluación continua consiste en diseñar e implementar un modelo analítico que cubra los requerimientos expuestos en el enunciado. Se ha estructura en 5 apartados que comprenden el análisis de la empresa en cuestión, los principales indicadores y dimensiones del proceso, el modelo lógico albergando las dimensiones, el informe en Power BI mostrando los KPIs establecidos y la implementación del modelo relacional definido en una base de datos.

## 1. Análisis de la empresa

Para la elaboración de esta PEC se va a analizar el negocio de la empresa SUPERSTORE, que es una tienda ecommerce que vende una gran variedad de productos clasificados principalmente entre muebles, material de oficina y aparatos tecnológicos, y todos ellos, a su vez, tienen subcategorías para definir aún más el tipo de producto. Esta amplia gama de productos les permite atacar diferentes sectores.

La empresa cuenta con una gran variedad de clientes definidos por tres segmentos, y sólo realiza envíos dentro de EEUU. Cada envío viene identificado por el país, el estado, la ciudad, la región y el código postal.

Los pedidos se encuentran clasificados por categorías que son entrega en el mismo día, primera clase, segunda clase y clase estándar, de forma que puedes escoger el envío que más se ajuste a tus necesidades. También se recoge la fecha del pedido y del envío, así como el identificador del cliente y del pedido.

En cuanto a los beneficios, debido a la agresividad del mercado, a descuentos por campañas promocionales, los productos pueden tener distinto precio en diferentes pedidos, y el beneficio también varía. Por lo tanto, tenemos una empresa que opera en un mercado agresivo, lo que obliga a que sus precios varíen, y solo en EEUU.

El objetivo es analizar el negocio de la empresa, de forma que, a partir del modelo relacional de datos alojado en la nube, se pueda construir un DW para posteriormente hacer uso de herramientas de Bussines Intelligence que permitan sacar más información del negocio de ventas de la empresa. El análisis de la empresa se va a centrar en los procesos del negocio de ventas, analizando particularmente tanto a los clientes como a los productos.

Se pretende almacenar toda la información de clientes, productos envíos y lugares en un único almacén de datos a partir del cual se pueda extraer información de múltiples maneras como a nivel de reporting y consultas ad-hoc o por preparación de cuadros de mando, aunque en este caso se hará uso de la herramienta Power BI.

Dentro de los clientes podemos obtener información muy útil sobre la operación de estos con la empresa como:

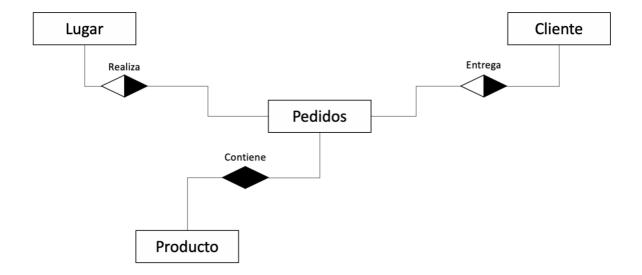
- Ranking de clientes por multitud de categorías como importe, margen o cantidad.
- Ranking de segmentos, es decir, en qué segmentos se obtiene un mayor importe.
- Análisis del tiempo de entrega por cliente en función del tipo de envío para comprobar la calidad del servicio con cada uno de ellos.
- Estudio de los clientes por ciudad y estado, que es importante a la hora de organizar los envíos.

Dentro de los productos también podemos obtener información muy útil para un mejor desarrollo de la empresa como:

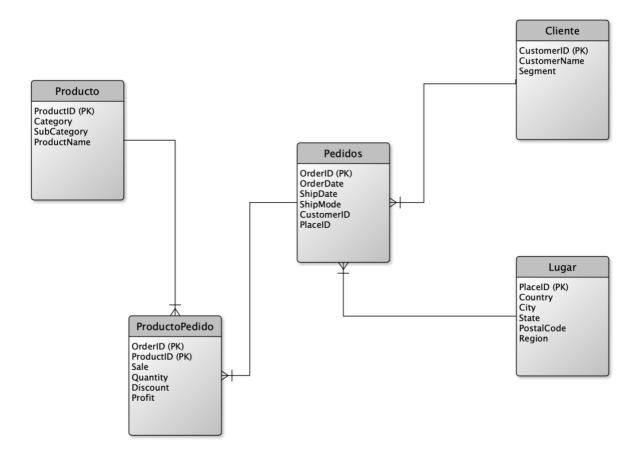
- Productos más vendidos.
- Productos que aportan un mayor beneficio.
- Tendencia de las ventas por categoría.
- Correlación entre la categoría de los productos y el segmento del cliente en las ventas.

Todo ellos son ejemplos de información que podríamos obtener mediante herramientas de Bussines Intelligence utilizadas para almacenar los datos expuestos en Data Warehouse. Ello ayudaría a conocer mejor a la empresa y a su negocio, porque aportaría más información acerca de los productos vendidos, de los clientes, de las localizaciones y de toda relación entre estos que interese conocer. Por lo tanto, es una forma de conocer mejor el negocio de las ventas y de maximizar los beneficios ya que se pueden tomar decisiones basadas en datos en vez de en impresiones.

Para llevar a cabo esta tarea, partimos de unos datos cuyo modelo de Entidad Relación es el siguiente:



Por lo tanto, habrá que desnormalizar el modelo de Entidad Relación para poder generar el modelo multidimensional que nos permita analizar el proceso de negocios de la empresa. También se expone el modelo transaccional de los datos generado a partir de las tablas aportadas:



## 2. Principales Indicadores y Dimensiones del Proceso de Ventas

En esta tarea de modelizar el negocio para entender qué tareas se llevan a cabo y definir las medidas más adecuadas para evaluar el rendimiento, es fundamental establecer indicadores que permitan, de manera objetiva, valorar el comportamiento de cualquier recurso, actividad o sistema.

Para poder establecer indicadores útiles y que aporten información, es necesario entender que un indicador es un dato que nos permite conocer el estado de una actividad, también conocido en el ámbito empresarial como Key Performance Indicator (KPI).

A la hora de establecer indicadores hay que definir el objetivo del indicador, las variables que afectan al mismo y la forma de calcularlo. También es necesario respetar las características principales de un KPI que son que debe ser cuantificable, inequívoco y realizable.

En el enunciado de la PEC se especifica que se ha de hacer un análisis de los productos y de los clientes, por lo que se procede a definir los KPI para ambos teniendo en cuento lo expuesto anteriormente.

KPIs para el análisis de los clientes:

- Beneficio obtenido por ventas por segmento: el objetivo de este KPI es el de conocer el beneficio que obtenemos por cada segmento de los clientes de la empresa, que permitirá conocer en que segmento se obtiene más rédito y poder orientar el negocio de la empresa hacia ese sector o intentar maximizar otros, ya que pueden tener más rango de mejora. Las variables que habrá que tener en cuenta son el beneficio del pedido y el segmento al que pertenece el cliente que ha realizado el pedido.
- Número de pedidos por segmento: el objetivo de este KPI es conocer en qué segmento tenemos un mayor número de pedidos, lo que nos ayudará a comprender mejor el anterior KPI al poder valorar a la vez el beneficio y el número de pedidos por segmento. Las variables que habrá que tener en cuenta son el identificador de los pedidos y el segmento al que pertenece el cliente que ha realizado el pedido.
- Tiempo medio de entrega por tipo de envío y segmento: el objetivo de este KPI es evaluar el nivel de la calidad del servicio de envío de la empresa al cliente. Las variables necesarias son las fechas de pedido y de entrega para obtener el tiempo de entrega por pedido, el tipo de envío y el segmento al que pertenece el cliente que ha realizado el pedido.
- **Numero de clientes por Estado:** el objetivo es analizar la distribución de los clientes en el país, que puede ser muy importante para el envío de productos. Las variables para analizar son el Estado y el identificador de los clientes.

KPIs para el análisis de los productos:

- Beneficio de ventas por categoría de producto: el objetivo de este KPI es conocer el beneficio que se ha obtenido en cada categoría de producto. Las variables que habrá que utilizar son el beneficio del pedido y categoría del producto vendido.
- Número de ventas por categoría de producto al año: el objetivo de este KPI es conocer la cantidad de productos y el tipo de estos que se venden cada año, lo que permitirá observar la distribución de las ventas de los productos y la evolución durante los años. Las variables que habrá que utilizar son el identificador del producto, el tipo de producto y el año.
- Productos vendidos por trimestre: el objetivo de este KPI es comprobar como varía la venta de productos entre los trimestres para comprobar si hay algún tipo de estacionalidad. Las variables que habrá que utilizar son el trimestre, el tipo de producto y el identificador del producto.
- Correlación entre Segmento y categoría de producto: el objetivo de este KPI es observar si existe alguna relación entre el tipo de cliente y el producto que compra. Este tipo de información puede ayudar a optimizar las relaciones con el cliente. Las variables a utilizar son el tipo de producto, el segmento y el identificador del producto.

Una vez definidas las métricas que nos van a ayudar a conocer más la empresa y a poder evaluar su rendimiento de una forma más objetiva, hay que definir las variables por las que podemos analizar las métricas y estas son nuestras dimensiones. Las dimensiones generadas a partir de los datos son:

- Dimensión Tiempo: es la dimensión básica de todos los modelos, ya que suele ser interesante analizar el tiempo. Los datos que generan esta dimensión provienen de las fechas de los pedidos. También es conveniente integrar un amplio número de atributos que puedan facilitar los análisis que se vayan a realizar, o simplemente atributos que se considere que puedan llegar a ser útiles para futuros análisis. Incluirá los siguientes atributos:
  - Fecha Id: es la fecha con la notación yyyymmdd tratada como entero y que será la clave de esta dimensión.
  - Fecha ISO: es la fecha en el formato ISO, que sería pasada a texto como 20 de noviembre de 2020.
  - Día Semana Id: día 1,2,3...7.
  - Día Semana Desc: día de la semana en texto.
  - Día Mes Id: número de día de la fecha en el mes.
  - Fin de semana: indicador de si la fecha es fin de semana o día entre semana.
  - Mes Id: notación año mes para comparativas (yyyymm). Clave que identifica cada mes.
  - Mes Desc: mes en formato descriptivo.
  - Num Mes Id: número del mes en el año. Puede ser útil para análisis tener el número del mes desvinculado del año.

- Trimestre Id: notación año-trimestre en formato descriptivo (yyyyt). Es la clave que va a identificar cada trimestre.
- Trimestre Desc: trimestre en formato descriptivo (Primer Trimestre).
- Num Trimestre: trimestre identificado por 1, 2, 3 o 4.
- Año Id: año de la fecha con 4 dígitos. Es la clave que va a identificar cada año.

La dimensión tiempo tendría la siguiente estructura incluyendo todos los atributos que se han mencionado:

# Tiempo

Fecha Id (PK)
Fecha ISO
Día Semana Id
Día Semana Desc
Día Mes Id
Fin de semana
Mes Id
Mes Desc
Num Mes Id
Trimestre Id
Trimestre Desc
Num Trimestre
Año Id

- **Dimensión Producto:** en esta dimensión se incluyen todos los atributos relacionados con los productos que se encuentran a la venta:
  - Producto Id: código del producto en el sistema operacional. Será la clave de esta dimensión.
  - Producto Nombre: datos identificativos del producto.
  - Categoría: tipo del producto según el sistema de clasificación interno de la empresa que comprende Furniture, Technology y Office Supplies.
  - Subcategoría: tipo del producto dentro de cada categoría principal. Añade un grado más de identificación al producto dentro del sistema operacional de la empresa.

Todos estos datos se encuentran en el sistema operacional, y la dimensión tendría la siguiente estructura:

### Producto

Producto Id (PK) Producto Nombre Categoría Subcategoría

- **Dimensión Cliente:** nos permite realizar el análisis desde la perspectiva de los atributos relacionados con el cliente. De vital importancia para mejorar el desarrollo de la empresa y asegurar que se ofrece el mejor servicio posible:
  - Cliente Id: código identificativo del cliente. Será la clave de esta dimensión.
  - Cliente Nombre: datos descriptivos del cliente.
  - Segmento: los clientes se encuentran agrupados internamente en segmentos, que son Consumer, Corporate y HomeOffice.

La dimensión cliente tendría la siguiente estructura incluyendo todos los atributos que se han mencionado:

#### Cliente

Cliente Id (PK) Cliente Nombre Segmento

- **Dimensión Lugar:** esta dimensión identifica el lugar de envío, y permite hacer el análisis desde esta perspectiva:
  - Lugar Id: código del lugar en el sistema operacional. Será la clave de esta dimensión.
  - País: identifica el país del envío, que será siempre Estados Unidos ya que la empresa solo realiza envíos en ese país, pero puede ser de utilidad incluirlo en caso de que en un futuro opere en más países.
  - Ciudad: permite agrupar por ciudad.
  - Estado: permite agrupar por estado.
  - Código Postal: permite identificar aún más la zona de envío.
  - Región: permite agrupar por la región dentro del estado.

La dimensión Lugar tendría la siguiente estructura incluyendo todos los atributos que se han mencionado:

Lugar Lugar Id (PK) País Ciudad Estado Código Postal Región

- **Dimensión Envío:** esta dimensión identifica el envío en sí. Se ha separado de la anterior porque se considera que es importante y aunque no haya mucha información en los datos aportados, tiene sentido pensar que el envío pudiera tener muchos más atributos y, por lo tanto, necesitar ser estudiado en una dimensión aparte:
  - Envío Id: código del envío. Será la clave de esta dimensión.
  - Tipo Envío: la empresa tiene 4 tipos de envíos que son Same Day, First Class, Second Class y Standard Class.

La dimensión Envío tendría la siguiente estructura incluyendo todos los atributos que se han mencionado:



- Tabla de Hechos: recoge valores de negocio que se quieren analizar para las perspectivas de la empresa. Contiene varias claves foráneas que se relacionan con las claves de las tablas dimensionales. A mayor número de claves, mayor será la granularidad de la tabla de hechos:
  - Cliente Id: identificador de la dimensión cliente.
  - Producto Id: identificador de la dimensión producto.
  - Envío Id: identificador de la dimensión envío.
  - Lugar Id: identificador de la dimensión lugar.
  - Fecha Id: identificador de la dimensión tiempo, que será la fecha del pedido.
  - Precio: precio de venta.
  - Cantidad: número de productos vendidos.
  - Tiempo Entrega: número de días que ha tardado en llegar el pedido.
  - Beneficio: beneficio obtenido por el pedido.
  - Descuento: no se ha utilizado para ningún KPI, pero puede se útil para futuros análisis.

Habrá muchos otros indicadores que se podrán construir a partir o cómo cálculo de los definidos en la tabla de hechos. Hay indicadores que puede que interese tener calculados en la base de datos por temas de diseño o por evitar errores en los cálculos, o simplemente puede que se calculen al ejecutar las consultas. La estructura de la tabla de hechos será la siguiente:

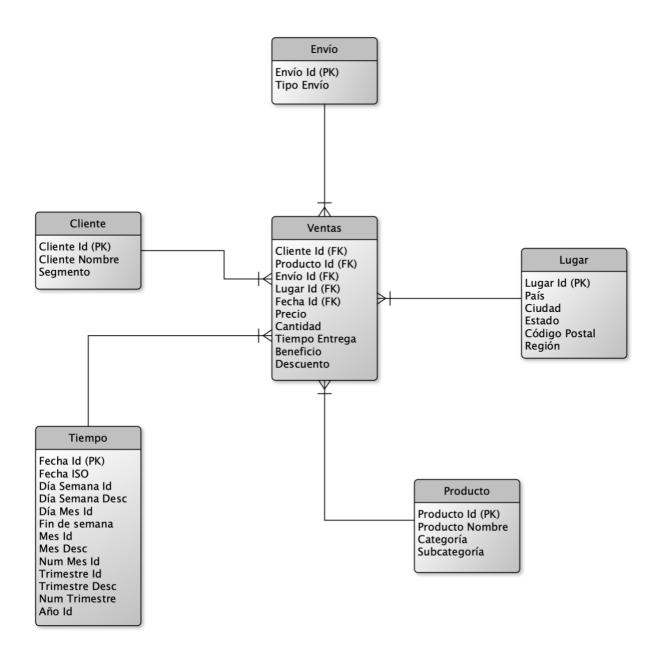
## Ventas

Cliente Id (FK)
Producto Id (FK)
Envío Id (FK)
Lugar Id (FK)
Fecha Id (FK)
Precio
Cantidad
Tiempo Entrega
Beneficio
Descuento

## 3. Desarrollar un modelo lógico que albergue todas las dimensiones

Una vez comentado el modelo transaccional de la empresa, descritos los KPI y las dimensiones a aplicar para el modelo multidimensional, es necesario definir la estructura de los datos a nivel físico en la base de datos relacional, que en este caso va a se un modelo en forma de estrella. Otras opciones eran el modelo en copo de nieve o de constelación. Todos ellos proporcionan un modelo físico orientado a la consulta y distinto al modelo relacional.

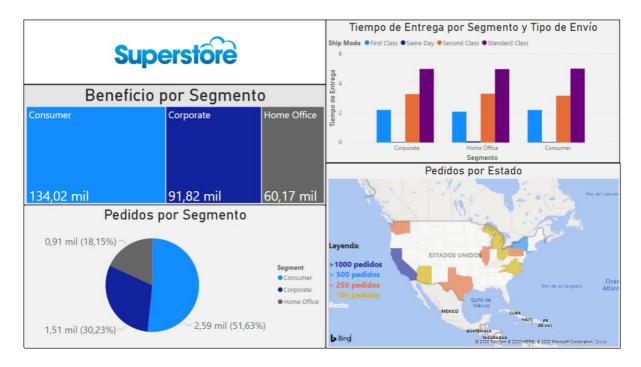
Esta es la arquitectura de almacenamiento más simple, cuyo esquema está definido por una base de datos relacional que consta de una sola tabla de hechos central rodeada de tablas de dimensiones. Se trata de un modelo desnormalizado. El esquema multidimensional recibe este nombre cuando no se explicita ninguna jerarquía física, a nivel de base de datos relacional, entre los atributos de las diferentes dimensiones del esquema, de forma que cada una de ellas almacena todos sus atributos.



## 4. Elaborar informe en PowerBI para visualizar los KPI comentados.

Para analizar los KPIs comentados en el apartado 2, se han creado dos dashboards, una para el análisis desde la perspectiva del cliente y otra para el análisis desde la perspectiva del producto. Para incluir poder visualizar los KPIs y comentarlos en el presente informe, se adjunta una captura de pantalla de cada uno de ellos.

KPIs del análisis desde la perspectiva del cliente:



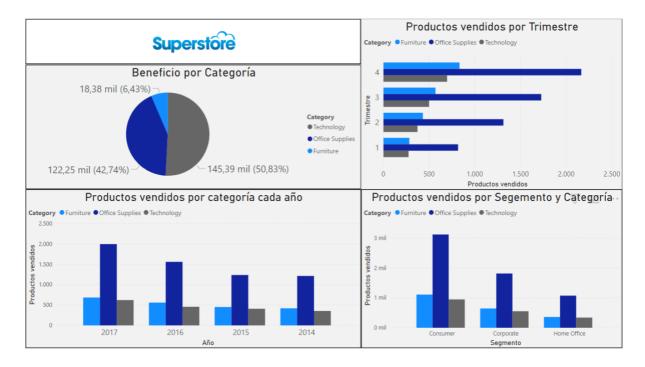
En la imagen anterior se puede apreciar el logo de la ficticia compañía (en este caso es el logo de una película) acompañado de los 4 gráficos que muestran los KPIs expuestos. En primer lugar, se aprecia el beneficio por segmento, para el que se ha elegido un gráfico treemap que permite observar el tipo de segmento, así como el beneficio neto obtenido ocupando un mayor espacio en el gráfico aquel segmento de mayor beneficio. En segundo lugar, encontramos los pedidos por segmento, donde se mantienen los mismos colores para los segmentos para hacer más entendible el informe, y se ha escogido un gráfico circular que permite observar que el orden en cuanto a beneficio se mantiene también en el número de pedidos, es decir, el segmento de mayor beneficio también es el de mayor número de pedidos.

En la parte derecha del informe tenemos el KPI de tiempo de entrega por segmento y tipo de envío, para el que se ha tenido que generar una variable nueva en Power BI, resultado de restar la fecha en la que se entregó el pedido menos la fecha en la que se ordenó el pedido para obtener los días que ha tardado la entrega. Se observa que el servicio de envío es idéntico para los 3 segmentos, por lo tanto, en caso de que no haya ningún tipo de cliente Premium, significaría que el servicio de envío funciona bien en ese aspecto. También muestra que el tiempo de entrega para la categoría Same Day es de 0 días, que es lo que se esperaba, pero quizá si que se podría conseguir un margen de mejora en el envío First Class, el cual podría tener una media más cercana a 2 para diferenciarse del envío Second Class cuyo

tiempo de entrega está entorno a 3 días. Por lo tanto, en una compañía de logística, los tipos de envíos tendrían asignados un tiempo de entrega, y este KPI permitiría medir si se está cumpliendo o no.

Por último, se muestran los pedidos por Estados en un mapa de los Estados Unidos. Se ha añadido una leyenda por colores de forma que se destacan los estados con un mayor número de pedidos a partir de una cierta cantidad, teniendo en cuenta que los estados con un número de pedidos inferior a 100 no han sido coloreados. De forma visual, se puede apreciar a que estados se realizan más envíos y podría ayudar a la distribución de los envíos. También, en la dashboard, permite seleccionar un estado y observar la información de los otros gráficos relativa a ese estado, por lo que permitiría de forma interactiva analizar los territorios deseados. Respecto a la generación de este KPI me gustaría comentar que no he conseguido que detectara el estado Florida, que se puede apreciar en el mapa ya que tiene el color por defecto al igual que los países vecinos.

Una vez comentado el análisis desde la perspectiva del cliente, se muestra el informa de los KPIs desde la perspectiva del producto:



Al igual que en el informe anterior, se comienza con la imagen del logo ficticio de la empresa. En primer lugar, podemos observar que se han mantenido los colores según la categoría del producto para todos los gráficos de forma que ayuda a la visualización del informe.

Se muestra en el primer KPI el beneficio por tipo de producto, observando que la tecnología es el producto que más beneficio aporta. En este caso, al contrario que con los clientes, el producto más vendido no es el que más beneficio aporta. Se puede comprobar que, la tecnología, a pesar de ser el producto menos vendido, es el que más beneficio aporta, por lo que un incremento en ventas de productos de tecnología debería influir en un positivo desarrollo de la empresa. También se divide los productos vendidos por año, viendo que la empresa está en crecimiento en los últimos años.

En la derecha del informe, podemos observar los productos vendidos por trimestre. Para este gráfico, se ha tenido que generar que una variable nueva que resulta de extraer de la fecha del pedido el mes en el que se generó, y a partir del mes, obtener el trimestre dividiéndolo por 3 y redondeando hacia el siguiente número de forma que obtenemos el trimestre en formato numérico. Se puede observar como el número de pedidos crece de un trimestre a otro, mostrando una clara estacionalidad en la venta de los productos.

Finalmente, se pretende buscar alguna correlación entre el segmento y el tipo de producto que compra para lo cual se ha generado este KPI, el cual no muestra ninguna correlación especial y los tres segmentos tienen una tendencia de compra de los productos similar.

Power BI es una herramienta de Business Intelligence que permite obtener de una manera muy sencilla gráficos que muestran a partir de los datos el funcionamiento de la empresa. En este caso se han mostrado alguno de los múltiples KPIs que se podrían haber obtenido. Por ejemplo, simplemente se ha pretendido analizar el tipo de producto, pero también se podría intentar obtener conclusiones sobre la subcategoría dentro del tipo de producto para conseguir más información que ayudasen a la hora de tomar decisiones para mejorar el desarrollo de la empresa e incrementar los beneficios.

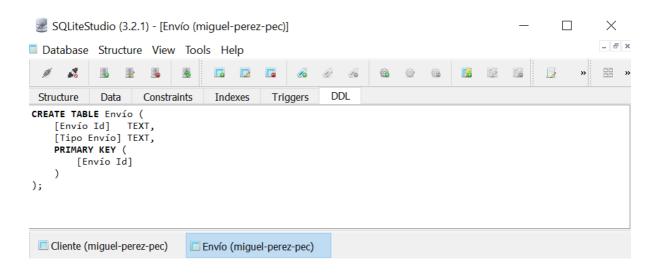
# 5. Implementar en una base de datos relacional el modelo definido y rellenarlo con los datos del Excel.

Para la realización de este último apartado se ha llevado el modelo lógico expuesto en el apartado 3 a una base de datos, en este caso, SQLStudio. Para ello, se comienza con la creación de todas las tablas, una por cada dimensión y otra para la tabla de hechos. Se han generado mediante los siguientes scripts:

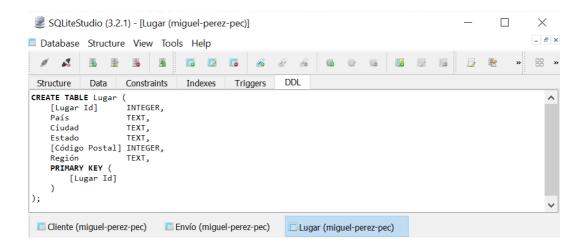
• Dimensión Cliente:

```
SQLiteStudio (3.2.1) - [Cliente (miguel-perez-pec)]
Database Structure View Tools Help
     ₽0
 Structure
             Data
                     Constraints
                                  Indexes
                                             Triggers
                                                        DDL
CREATE TABLE Cliente (
                      TEXT,
    [Cliente Id]
    [Cliente Nombre] TEXT,
                      TEXT,
    Segmento
    PRIMARY KEY (
         [Cliente Id]
);
```

• Dimensión Envío:



### • Dimensión Lugar:



#### Dimensión Producto:



#### • Dimensión Tiempo:

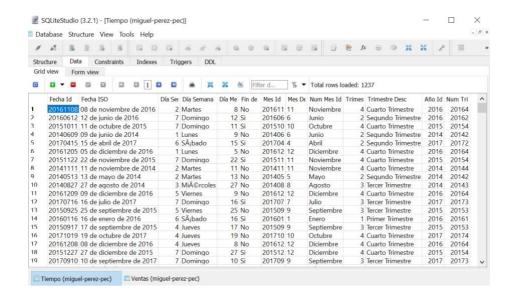
```
SQLiteStudio (3.2.1) - [Tiempo (miguel-perez-pec)]
                                                                                                                                     П
                                                                                                                                               X
                                                                                                                                              _ 8 x
Database Structure View Tools Help
  Structure Data Constraints Indexes Triggers
                                                                   DDL
CREATE TABLE Tiempo (
     [Fecha Id]
[Fecha ISO]
                            TEXT
     [Día Semana Id] INTEGE
[Día Semana Desc] TEXT,
                            INTEGER,
     [Día Mes Id]
[Fin de Semana]
                           INTEGER,
                           TEXT,
     [Fin de Semana] (LA.),
[Mes Id] INTEGER,
[Mes Desc] TEXT,
[Num Mes Id] INTEGER,
[Trimestre Id] INTEGER,
[Trimestre Desc] TEXT,
[Num Trimestre] INTEGER,
INTEGER,
INTEGER,
INTEGER,
INTEGER,
INTEGER,
INTEGER,
     [Año Id]
PRIMARY KEY (
                            INTEGER,
         [Fecha Id]
);
 Tiempo (miguel-perez-pec)
```

• Tabla de Hechos Ventas:

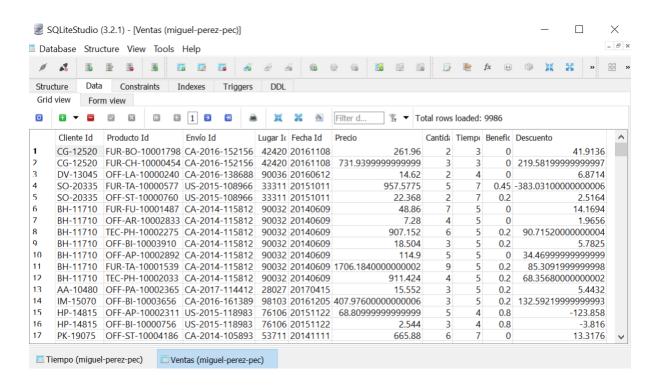
```
SQLiteStudio (3.2.1) - [Ventas (miguel-perez-pec)]
Database Structure View Tools Help
 Structure
            Data
                    Constraints
                                  Indexes Triggers
                                                       DDL
CREATE TABLE Ventas (
                      TFXT.
    [Cliente Id]
    [Producto Id]
                      TEXT.
    [Envío Id]
                      TEXT,
    [Lugar Id]
                      INTEGER,
                     TEXT,
NUMERIC,
    [Fecha Id]
    Precio
    Cantidad
                      INTEGER.
    [Tiempo Entrega] INTEGER,
                     NUMERIC
    Beneficio
    Descuento
                     NUMERIC
    FOREIGN KEY (
        [Cliente Id]
    REFERENCES Cliente ([Cliente Id]),
    FOREIGN KEY (
        [Producto Id]
    REFERENCES Producto ([Producto Id]),
    FOREIGN KEY (
        [Lugar Id]
    REFERENCES Lugar ([Lugar Id]),
    FOREIGN KEY (
        [Envío Id]
    REFERENCES Envio ([Envio Id]),
    FOREIGN KEY (
        [Fecha Id]
    REFERENCES Tiempo ([Fecha Id])
);
```

Mediante los scripts que se acaban de mostrar, se generan todas las tablas, para después añadir a todas ellas los datos correspondientes con las modificaciones que hayan sido necesarias para generar los datos de cada tabla. A modo de ejemplo, se muestran en SQLStudio los datos de las tablas correspondientes a la dimensión tiempo y a la tabla de hechos ventas, que son los datos que necesitaban más modificaciones para llevar a cabo la desnormalización necesaria para la generación del modelo en estrella:

Datos de la dimensión Tiempo:



Datos de la tabla de hechos Ventas:



A partir de este modelo, también podríamos conectarlo con Power BI u otra herramienta de Business Intelligence para llevar a cabo cualquier tarea de análisis que sea necesaria para descubrir el funcionamiento y desarrollo de la empresa a partir de los datos.